

SoundShape — 목소리의 감정을 눈으로 읽는 자막


운율 **측정**과 AI 분류를 분리한 하이브리드 감정 시각화 시스템

저자명 · 소속 고등학교 · 지도교사 (저자 정보 자리)

자막은 무엇을 말했는가만 전달한다. SoundShape은 운율을 측정하고 AI로 감정을 분류해 **파형 형태**의 시각 언어로 자막 위에 겹쳐, **어떻게 말했는가**를 눈으로 읽게 한다.

01 PROBLEM

감정은 어조에 실린다



말 내용과 어조가 어긋날 때 청자가 의존하는 비율 (Mehrabian) [1][2]

감정은 음높이·세기·떨림에 물리적으로 부호화되어 있다 [3][4]. **분석하면 되살릴 수 있다.**

4.3억 전 세계 청력 손실 [5] 44만 국내 등록 청각장애인 [6]

02 SAME WORDS

같은 “괜찮아”가 위로 · 분노 · 비꼼 · 체념



같은 “괜찮다고!!”를 말투에 따라 다르게 그린 실제 화면 — 분노 · 슬픔 · 체념 · 위로. 자막 글자는 넷 모두 같다.

텍스트 기반 감정 분석은 “잘~한다” 같은 반어를 **원리적으로** 놓친다. 비꼼은 단어가 아니라 **운율**에 표시되기 때문이다 [8].

03 RELATED WORK

기존 접근의 한계 · 차별점

일반 자막	대사만 전달. 감정 정보 전무
텍스트 감정 분석	반어를 원리적으로 놓친다 [8]
음성 감정 인식 [3][4]	감정을 라벨로 분류. 시각 언어로 번역한 사례는 드물다

Caption with Intention (2025) 글자 자체를 변형하고 영화별로 사전 제작된다 [19]


차별점 — ① 운율 기반(비꼼 포착) ② 연속 감정 공간 [9] ③ 다채널 시각 언어 ④ 연구 기반 매핑 ⑤ 접근성 우선 설계

글자를 변형하지 않은 것은 농인 시청자가 이를 선호하지 않았다는 결과 [7] 때문이며, 임의의 영상에 **실시간**으로 동작한다. 당사자도 청각장애인에 국한되지 않는다 — 아동 [10], 자폐 스펙트럼 [11], 사이코패스 성향 [12].

04 PIPELINE

처리 파이프라인

아래 기능 블록 ①~⑦의 지도



확신도가 낮으면 어휘에 투명도를 낮춘다 — 크기와 음색은 측정값이므로 그대로 유지한다

기능 위치 — ① 음원 분리 · ② 감정 인식 · ③ 화자 전환 · ④ 하이브리드 렌더링 · ⑤ 캘리브레이션 · ⑥ 저확신 루프 · ⑦ 탭틱

05 MAPPING

감정 → 시각 매핑 근거

채널	규칙 · 근거	출처
모양	각진 = 위협, 둥근 = 안정 Aronoff(1992) [13]; Bar & Neta(2006) [14]	AI 판단
색상	빨강·파랑·노랑·회색 = 분노·슬픔·행복·중립 Hupka(1997) [15]	AI 판단
밝기	명도 ∝ 정서 Valdez & Mehrabian(1994) [16]	AI 판단
채도	채도 ∝ 각성 Valdez & Mehrabian(1994) [16]	측정값
크기	크기 ∝ 각성 Russell(1980) [17]; Ohala(1994) [18]	측정값
움직임	빠르고 거친 움직임 = 고각성 Pollick(2001); Banse & Scherer(1996) [3]	측정값
투명도	확신이 낮으면 표현을 절제 Bonneau et al.(2014)	AI 확신도

“왜 분노가 빨강인가”에 답할 수 있도록 7채널 전부를 논문에 근거하게 했다.


1 > 2 > 3 > 4 > 5 > 6 > 7 입력 직후 01 ① 음원 분리

임계값을 취향이 아니라 실측으로 정했다

어떻게 작동하는가

HDemucs [24]로 배경음악을 분리하고 **음성 트랙만** 분석한다. torchaudio 내장이라 추가 의존성이 없다 (52초 오디오 · CPU 10.1 초).

모든 영상에 적용하면 효과가 없어도 처리 시간을 지불한다. 그래서 **앞 20초만 먼저 분리해 음악 에너지 비율을 재고, 0.45 미만이면 건너뛴다.**



음악 에너지 비율 — 효과가 없던 0.281보다 크고, 효과가 확인된 가장 낮은 0.472보다 작다

그림

FIGURE PLACEHOLDER · 16:9 × 2

원본 파형 ↔ 분리된 음성 파형 비교

같은 구간을 분리 전 / 후로 나란히. 캡처 예정

결과

조건	분리 없음 → 함	McNemar
깨끗한 원본 (상한)	73.5%	—
SNR +10dB	71.0 → 73.3%	p=0.27 유의하지 않음
SNR +5dB	68.1 → 73.8%	p=0.009
SNR 0dB	60.8 → 71.5%	p=1.2×10 ⁻⁵

모든 상황을 개선하는 기능이 아니라, **음악이 대사를 덮는 지점부터 작동하는 기능**이다.

한계 — 혼합에 쓴 음악은 합성음이며 실제 오케스트라보다 분리가 쉽다. 개선폭은 상한으로 해석해야 한다.

1 > 2 > 3 > 4 > 5 > 6 > 7 분석 단계 02 ② 감정 인식

모든 정확도는 화자 독립 교차검증


어떻게 작동하는가

wav2vec2-large-robust(영어) / **XLSR-korean**(한국어)으로 감정 카테고리 and 정서·각성을 얻고, PRAAT **운율 15종**을 함께 쓴다.

평가는 **GroupKFold 8겹 화자 독립** — 학습에서 본 목소리는 평가에 쓰지 않는다.


데이터	제로샷	학습 후
영어 RAUDES 4분류	55.0%	79.8%
영어 RAUDES 8분류	—	74.2%
한국어 AIHub 7분류 우연 = 14.3%	17.5%	49.6%

그림 — 혼동행렬



영어 4분류 · 학습 후 · 화자 독립

행 = 정답, 열 = 예측. 한국어에서는 오답이 특정 쌍에 몰리지 않고 넓게 퍼진다.



한국어 7분류 · N=1750 · 정답 = 평가자 5인 다수결

★ 한국어 49.6%를 어떻게 읽어야 하는가

우연 대비 (49.6% vs 14.3%)	3.47배
인간 상한 — 한 평가자가 다수결을 맞히는 정확도	51.5%
인간 상한 대비 도달률	96.3%
라벨 일치도 — 평가자 5인 Fleiss κ	0.344

모델의 한계라기보다 **정답 자체가 본질적으로 모호한 과제**.

XLSR-korean 채택으로 43.6% → 49.6% (McNemar p<0.001). κ=0.344는 “보통” 수준.

1 > 2 > 3 > 4 > 5 > 6 > 7 분석 단계 · ②와 병렬 03 ③ 화자 전환 감지

표기 선택이 알고리즘 난이도를 결정했다

어떻게 작동하는가

ECAPA-TDNN [25] 화자 임베딩으로 앞 구간과 비교한다. 사람이 바뀌면 자막 앞에 **긴 대시(—)**를 붙인다 — 방송 자막의 국제 표준 표기다.

이름이 아니라 대시를 쓴 것은 설계의 문제다. 이름은 영상 전체의 화자 신원 추적(화자 수를 모르는 군집화)을 요구하지만, 대시는 “앞 줄과 다르다”만 주장하므로 **인접 비교로 충분**하다.

색·위치를 안 쓴 이유 — 색은 이미 감정을 뜻하므로 한 채널이 두 의미를 갖게 되고, 좌우 위치는 화면 속 배우 위치와 어긋나면 혼란을 준다.

그림

FIGURE PLACEHOLDER · 16:9

자막 앞에 대시(—)가 붙은 화면

2인 대화 구간의 연속 자막 2~3줄. 기능 비활성 상태이므로 캡처 예정

결과

화자 전환 감지 AUC · 4,000쌍	0.958
발화 연속열 정확도 · 오펜 3 · 미탐 3	92.9%
최소 구간 1.0초 · 0.5초 0.904 처리 비용	0.978 · 36ms
감정 임베딩으로는 화자 구분 불가 (ARI)	0.102 → 0.821

임계값은 정확도 최고점(0.60 · 94.9%)이 아니라 **정밀도 기준(0.70 · 97.3%)**. 잘못된 대시는 없는 정보를 만들지만, 누락된 대시는 현재 상태를 유지할 뿐이다.

⚠ **측정하지 못한 것** — 자막과 결합한 전 과정 성능은 측정하지 못했다. RAUDES는 문장이 두 개뿐이라 Whisper 반복 억제로 발화의 40~44%가 전사되지 않는다. **실제 2인 대화 영상으로 검증하기 전까지 이 기능은 비활성 상태로 둔다.**

측정과 추론을 나눈 결과

AI가 틀린 구간에서 개선폭이 가장 컸다 — 그리고 사람이 감정을 읽어 냈다

2

1 > 2 > 3 > 4 > 5 > 6 > 7 매핑 단계 04 ④ 하이브리드 렌더링


측정할 수 있는 것은 측정하고, 추론이 필요한 것만 AI에 맡긴다

어떻게 작동하는가

오차는 전부 분류 단계에서 생긴다. 그러나 운율 측정값 자체는 틀리지 않는다 — F0가 187Hz라는 것은 사실이다. 그래서 경계를 그곳에 그었다.


측정값 크기·채도·움직임

AI 판단 모양·색상·밝기



각성 측으로는 감정이 잘 갈라지지만 정서가 측으로는 뭉쳐 있다(원본 산점도 재작도 · 겹친 점 병합).

그림 — 채널 분할 측정값 / AI 판단



PLACEHOLDER 하이브리드 / AI 전용 비교 스크린샷 — SS.compare() 캡처 예정

결과 — 크기 채널 AUC

구간	full_ai → hybrid	차이
전체 480개	0.750 → 0.812	+0.062 p<.0001
분류기가 틀린 127개	0.722 → 0.833	+0.112 p=.005
분류기가 맞힌 353개	0.760 → 0.802	+0.042 p=.026
채도 채널	0.773 → 0.826	+0.053

AI가 틀린 구간에서 개선폭이 2.7배 크다. 하이브리드가 틀린 구간의 0.833은 full_ai가 맞힌 구간의 0.760보다도 높다.

RAVDSS 480개의 보통/강함 강도 라벨을 정답으로, 부트스트랩 5000회. 스스로 불리하게 잡은 것 — full_ai의 각성도는 학습시킨 적 없는 사전학습 모델에서 나오고, 카테고리별 화자 독립 교차검증으로 다시 예측했다(73.5%).

1 2 3 > 4 5 > 6 > 7 05 ⑤ 개인 캘리브레이션

수집 중

어떻게 작동하는가

청각장애인은 균질한 집단이 아니다. 잔존청력·발병 시기에 따라 색을 잘 읽는 사람과 움직임을 잘 읽는 사람이 갈린다. 약 5분 검사로 채널별 판별력을 재고 표현 폭을 조정한다.

구분 검사(“이 둘이 같은가”)와 의미 검사(“어떤 감정인가”)를 나눈다 [22]. 안 보이면 표현 폭을 넓히고, 보이는 데 뜻이 안 통하면 다른 채널로 역할을 이관한다.

사람은 신뢰도 높은 감각에 더 큰 가중치를 둔다 [20]. 다만 약한 채널도 끄지 않는다(하한 0.6) — 중복 부호화가 정확도와 반응 속도를 함께 높이기 때문이다 [21].

FIGURE PLACEHOLDER · 4:3

/study 검사 화면
구분 검사 문항 예시 · 캡처 예정

RESULT PLACEHOLDER

결과 수치 자리 — 측정 예정

설계만 확정: 40문항 · 2단계 무작위 제시 · McNemar · 교차 상호작용 검증 — 학습 스타일 이론이 무너진 지점을 피한 설계 [23]

참가자 0명

1 2 3 > 4 5 > 6 > 7 06 ⑥ 저확신 학습 루프

라벨 0건

어떻게 작동하는가

한국어 정확도의 주된 원인은 도메인 불일치다. 모델은 AIHub 대화 음성으로 학습했지만 사용자는 드라마를 본다.

드라마 감성 라벨 데이터는 어디에도 없으나, 사용자가 지금 보고 있는 것이 바로 그 데이터다.

확신도가 임계값 아래로 떨어질 때만 화면 구석에 짧은 질문이 뜨고, 답변은 저장된 수치와 연결되어 재학습에 쓰인다. 질문은 2분에 1회 · 영상당 5회로 제한한다.

음성은 저장하지 않고 분석된 수치만 보관한다. 확신이 낮은 구간은 이미 투명도로 표현이 절제되므로, 되묻는 지점과 절제하는 지점이 같다.

FIGURE PLACEHOLDER · 4:3

피드백 질문 카드 화면
저확신 구간에 뜨는 질문 UI · 캡처 예정

RESULT PLACEHOLDER

개선 폭 자리 — 측정 예정

솔수목 나타지는 구조는 만들었고, 개선 폭은 데이터 축적 후 측정한다

라벨 0건

1 2 3 > 4 5 > 6 > 7 출력 채널 추가 07 ⑦ 햅틱 채널 — 손목 밴드

제작 예정 · 미구현

향후 과제 — 결과 수치 없음

어떻게 작동할 것인가

시청자는 배우의 얼굴·자막·감정 시각화 세 가지를 동시에 봐야 한다. 시각 채널은 이미 포화 상태이며, 촉각은 유일하게 비어 있고 시선을 전혀 요구하지 않는 채널이다 [20].

측정한 세기를 손목 진동으로 전달하면 화면을 보지 않고도 말의 리듬·강조·침묵을 느낄 수 있다.

구성 (예정)

ESP32-S3 Feather + DA7280(LRA 모터 일체형), Qwiic 케이블 연결 — 납땜 0회 · 배터리 0개. 브라우저가 Web Serial API로 USB를 통해 직접 통신한다.

진동 세기는 백엔드가 PRAAT으로 이미 계산한 값을 쓰므로 화면의 시각화와 진동이 같은 숫자에서 나온다.

PHOTO PLACEHOLDER · 4:3
밴드 실물 사진
제작 후 삽입

RESULT PLACEHOLDER
동작 확인 결과 자리
미제작 · 측정 예정 (숫자 없음)

08 전체 시스템 검증 — 사용자 실험 ★ 개별 기능이 아니라 시스템 전체를 사람에게 시험한 유일한 결과

n = 6 · 대응표본 t검정

설계 · 조건 A / B

참가자 6인이 동일한 클립을 두 조건에서 보고 감정을 답했다.


조건 A — 자막만

무음 상태에서 자막만 읽는다

조건 B — 자막 + SoundShape

동일 클립에 파형 시각화를 겹친다

결과 — 조건 A / B 대비



비품에서의 0% → 67%는 자막만으로는 아무도 반어를 읽지 못했지만 SoundShape를 더하자 다수가 정확히 읽었음을 뜻한다. “말투가 글자를 이긴다”는 핵심 가설의 직접 증거다.

결과 표

감정 인식 정확도 · A → B	27% → 73%
비품 및 억눌린 감정 클립	0% → 67%
향상 폭	+46%p
대응표본 t검정	p = 0.016
평균 확신도 (5점)	3.3 → 3.5
이 73%는 청인이 목소리를 직접 듣고 감정을 인식하는 수준인 약 66%에 근접하는 값이다.	

한계 — 표본이 6인으로 적고, 정상 청각자의 무음 실험이며, 같은 클립을 두 조건에서 본 설계다. 추후 청각장애인 당사자 및 대규모 표본으로 보완해야 한다.

09 한계 — 숨기지 않는다

표본 크기 사용자 실험 6인. 청각장애인 당사자 검증 없음

한국어 정확도 49.6%. 인간 상한의 96%이나 절대값은 낮다

음원 분리 평가 합성 음악 기준이므로 개선폭은 상한

화자 구분 모듈 단위만 검증. 전 과정 미검증 → 비활성

캘리브레이션 참가자 0명 · 결과 없음 (PLACEHOLDER)

햅틱 미구현 — 부품만 확보, 제작 전 (PLACEHOLDER)

정서가 예측 r=0.42로 약함. 밝기 채널만 이 한계에 남아 있다

10 결론 · 향후 과제

핵심 기여는 측정과 추론의 경계를 어디에 그을 것인가에 대한 답이다. AI 분류가 완벽하지 않다는 사실을 시스템 설계로 흡수했다 — 틀릴 수 있는 채널과 틀릴 수 없는 채널을 나누고, 사용자가 둘을 즉시 비교할 수 있게 했다. 그 결과 AI가 감정을 틀린 구간에서 오히려 개선폭이 가장 컸다.

향후 과제

01 청각장애인 당사자 대상 검증 — 현재 가장 큰 공백

02 햅틱 채널 구현 (PLACEHOLDER)

03 캘리브레이션 참가자 수집 (PLACEHOLDER)

04 실제 2인 대화 영상으로 화자 구분 검증

05 저확신 학습 루프의 실사용 데이터 축적

REFERENCES

[1] Mehrabian & Wiener (1967). Decoding of inconsistent communications. *JPSP*. [2] Mehrabian & Ferris (1967). Inference of attitudes from nonverbal communication in two channels. *J. Consulting Psychology*. [3] Banse & Scherer (1996). Acoustic profiles in vocal emotion expression. *JPSP*. [4] Juslin & Laukka (2003). Communication of emotions in vocal expression and music performance. *Psychological Bulletin*. [5] WHO. World report on hearing. [6] 보건복지부 (2024). 동국장애인 현황. [7]

농인 시청자 자막 선호 연구. [8] Cheang & Pell. The sound of sarcasm. *Speech Communication*. [9] Russell (1980). A circumplex model of affect. *JPSP*. [10] Grosbras et al. (2018). Development of emotion recognition from voice. *Scientific Reports*, 8, 14791. [11] Zhang et al. (2022). Affective prosody recognition in autism: a meta-analysis. [12] Dawel et al. (2012). Emotion recognition deficits in psychopathy: a meta-analysis. [13] Aronoff et al. (1992). Which are the stimuli in facial displays of anger and happiness? [14] Bar & Neta (2006). Humans

prefer curved visual objects. *Psychological Science*. [15] Hupka et al. (1997). The colors of anger, envy, fear, and jealousy. *JCCP*. [16] Valdez & Mehrabian (1994). Effects of color on emotions. *JEP: General*. [17] Russell (1980). (동일) [18] Ohala (1994). The frequency code underlies the sound-symbolic use of voice pitch. In *Sound Symbolism*. [19] FCB Chicago, AMPAS, & Chicago Hearing Society (2025). Caption with Intention. *Cannes Lions Titanium*. [20] Ernst & Banks (2002). Humans integrate visual and haptic information

in a statistically optimal fashion. *Nature*, 415(6870), 429–433. [21] Miller (1982). Divided attention: evidence for coactivation with redundant signals. *Cognitive Psychology*, 14(2), 247–279. [22] Green & Swets (1966). *Signal Detection Theory and Psychophysics*. Wiley. [23] Pashler et al. (2008). Learning styles: concepts and evidence. *PSP*, 9(3), 105–119. [24] Defossez et al. (2021). Hybrid spectrogram and waveform source separation. *ISMIR*. [25] Desplanches et al. (2020). ECAPA-TDNN. *Interspeech*.