


1. 개발 배경 및 필요성

청각장애인은 자막을 통해 대사는 읽을 수 있지만, 화자의 말투에 담긴 감정은 이해하기 어렵다. 예를 들어 같은 “괜찮아”라는 문장도 위로, 분노, 비꼼, 체념 등 다양한 감정을 담을 수 있지만 일반 자막은 모두 동일하게 표시된다. 이로 인해 청각장애인은 영상·미디어 콘텐츠에서 중요한 감정 정보를 놓칠 수 있다.



이 문제는 소수의 사용자에게만 해당되는 문제가 아니다. 세계보건기구(WHO)는 전 세계적으로 약 4억 3천만 명(세계 인구의 5% 이상)이 재활이 필요한 수준의 청력 손실을 겪고 있다고 보고했다. [5] 우리나라의 등록 청각장애인도 2024년 말 기준 약 44만 명(전체 등록장애인 263만 명의 16.8%, 2위 유형)에 이른다. [6] 이들에게 영상 미디어는 단순한 오락이 아니라 사회 및 문화에 참여하는 통로다. 그러나 현재의 자막은 대사만 전달할 뿐 감정을 전하지 못해, 청각장애인은 비장애인과 같은 영상을 보고도 이야기를 오관할 가능성이 높다. 따라서 자막에 감정을 더하는 일은 단순한 편의 제공을 넘어 문화적 접근권을 보장하는 문제다.

심리학자 Mehrabian의 고전적 실험에 따르면, 말의 내용과 목소리 어조가 서로 어긋나게 감정과 태도를 전달할 때, 청자는 어조(목소리 톤)에 약 38%, 말의 내용에 약 7%를 의존했다(나머지 약 55%는 표정). [1][2] 즉, 감정이 전달되는 상황에서는 무엇을 말했는가보다 어떻게 말했는가 훨씬 큰 비중을 차지한다. 그런데 영상의 자막은 오직 단어만 전달한다. 목소리에 담긴 감정 정보는 자막에서 사라진다.

목소리에는 감정이 실제로 담겨 있다는 것은 한 연구를 통해 증명되었다. Banse와 Scherer는 분노, 기쁨, 슬픔 등 각 감정이 음높이, 세기, 떨림 등에서 서로 구별되는 고유한 음향 프로파일을 가짐을 실험으로 보였다. [3] 또한 Juslin과 Laukka의 대규모 메타분석은 청자가 여러 문화권에 걸쳐 음성만으로 화자의 감정을 우연보다 훨씬 높은 정확도로 인식함을 확인했다. [4] 즉, 감정은 목소리의 운율에 물리적으로 부호화되어 있으며, 따라서 음성을 분석하면 감정을 되살릴 수 있다.

나아가 이 문제의 당사자는 청각장애인에 국한되지 않는다. 목소리에 담긴 감정을 읽는 능력 자체가 아직 발달하지 않았거나 손상된 사람들도 같은 어려움을 겪는다. 첫째, 어린아이는 목소리로 감정을 읽는 능력이 천천히 자란다. Grosbras 등(2018)은 음성만으로 감정을 범주화하는 능력이 아동기 내내, 나아가 청소년기까지도 계속 향상되며 그때까지도 성인 수준에 이르지 못함을 실험으로 보였다. [10] 둘째, 자폐 스펙트럼인 사람은 운율에서 감정을 추출하는 데 어려움을 겪는다. Zhang 등(2022)의 메타분석은 자폐군이 비자폐군에 비해 정서적 운율(affective prosody) 인식에서 중간~큰 수준으로 낮음을 확인했다. [11] 셋째, 사이코패스 성향이 높은 사람도 목소리의 감정을 잘 읽지 못한다. Dawel 등(2012)의 메타분석은 이들이 공포/슬픔에 그치지 않고 여러 감정에 걸쳐, 얼굴뿐만 아니라 목소리에서도 광범위한 감정 인식 결손을 보임을 밝혔다. [12] 이처럼 목소리의 감정을 놓치는 어려움은 청각장애인에게만 국한되지 않는다. 감정 인식이 미숙하거나 손상된 여러 사람이 같은 어려움을 공통으로 겪는다. 따라서 목소리의 감정을 눈에 보이는 형태로 옮겨 주는 SoundShape는 청각장애인을 넘어 이들 모두에게 감정 이해를 돕는 보조 수단이 될 수 있다.

2. 주제(목적)

2.1 개발의 주제 및 목적

본 작품 SoundShape는 음성의 운율을 분석하고 인공지능으로 감정을 추출한 뒤, 이를 도형, 색, 크기, 움직임의 시각 언어로 변환하여 영상 위에 자막과 함께 보여 주는 시스템이다. 목적은 청각장애인이 대사와 감정을 함께 이해하도록 하는 것이며, 나아가 자폐 스펙트럼 등 감정 인식에 어려움을 겪는 이들로 확장하는 것이다.

2.2 해결 방법

음성을 다음 세 단계로 처리한다.

1. 음성 인식(자막): Whisper 모델로 발화를 글자와 단어 단위의 타임스탬프로 변환한다.
2. 감정 분석: 각 발화 구간에서 운율(음높이, 세기, 떨림 등)을 PRAAT로 추출하고 [3], 딥러닝(wav2vec2; 한국어는 한국어 특화 XLSR-korean 임베딩)으로 감정을 분류한다.
3. 시각 번역: 추출한 감정을 연구에 근거한 규칙으로 도형, 색, 크기, 움직임으로 바꾸어 자막과 동기화해 표시한다.

3. 유사 제품(연구) 및 차별점

기존 자막	SoundShape 시스템
대사만 전달	대사 + 감정 전달
비꼼·역설 표현 어려움	말투의 감정 전달 가능
텍스트 중심	음성 자체 분석
감정 정보 소실	감정 정보 시각화
사전 수작업 제작(영화 단위)	음성 분석 기반 자동·실시간(임의 영상)

3.1 일반 폐쇄자막(Closed Caption)

대사를 글자로 보여 주고 [음악] 및 [웃음] 같은 소리 상황을 일부 괄호로 표기한다. 그러나 음악, 효과음, 말의 운율(감정) 정보는 사실상 자막에서 빠져 있다는 점이 선행 연구에서 지적되었다. [7] 특히 화자의 감정 자체를 표현하지 못해, 비꼼처럼 말과 뜻이 반대인 경우를 전혀 구분할 수 없다. 또한 Rashid 등은 자막 글자 자체를 움직여(animated text) 감정을 전하려 했으나, 실험에서 농인(deaf) 시청자는 글자를 변형하는 방식을 선호하지 않았다. [7] 본 작품이 글자를 건드리지 않고 별도의 시각 언어로 감정을 전하는 이유가 여기에 있다.

3.2 텍스트 감성분석 기반 이모지 자막

일부 서비스는 자막 텍스트를 감성 분석해 이모지를 붙인다. 그러나 이는 단어를 보고 감정을 추측하므로, "잘~한다"처럼 긍정 단어로 비꼬는 경우 오히려 반대로 표시한다. 실제로 비꼼은 단어가 아니라 운율(낮아진 음높이 및 음질 변화 등)에 표시되므로 [8], 텍스트만 보는 방식은 원리적으로 이를 놓친다. 또한 감정을 몇 개의 고정된 이모지로 단순화한다.

3.3 (연구) 음성 감정 인식(SER)

학계에는 음성에서 감정을 분류하는 연구가 활발하다. [3][4] 그러나 이는 감정을 라벨로 분류하는 데 초점을 두며, 청각장애인이 영상에서 즉시 읽을 수 있는 '시각 언어'로 번역하거나 접근성 도구로 구현한 사례는 드물다. 본 작품은 이 연구 성과를 실제 접근성 제품으로 이끈다.

3.4 (사례) Caption with Intention

2025년 칸 라이언즈에서 Titanium 등 다수 부문을 수상한 Caption with Intention(FCB Chicago·미국 영화예술과학아카데미 협업)은 자막 글자 자체에 색(화자), 크기(음량), 움직임(억양)을 입혀 감정을 전달한다 [19]. 세계 최대 규모의 크리에이티브 어워드가 이 문제에 최고상을 수여한 것은, 기존 자막이 감정을 전달하지 못한다는 본 작품의 문제의식이 산업적으로도 공인된 과제임을 보여준다. 다만 접근은 다르다. 첫째, 해당 시스템은 글자를 직접 변형하지만, 본 작품은 농인 시청자가 글자 변형을 선호하지 않았다는 실험 결과 [7]에 근거해 자막 가독성을 보존하는 별도 시각 채널을 택했다. 둘째, 해당 시스템은 영화별로 사전 제작되는 반면, 본 작품은 음성에서 운율을 자동 추출해 임의의 영상에 실시간 적용되므로, 전문 제작이 닿지 않는 일상 미디어 전반으로 감정 접근성을 확장한다.

3.5 본 작품의 차별점 (5가지)

1. 운율 기반: 텍스트가 아니라 소리 자체를 분석하므로 비품을 포착한다. [3][8]
2. 연속 감정 공간: Russell의 정서가 × 각성 평면 [9]을 사용한다.
3. 다채널 시각 언어: 하나의 형태가 모양, 색, 크기, 움직임으로 감정을 동시에 전달한다.
4. 연구 기반 매핑: 모든 시각 규칙이 논문에 근거한다(II장 참조).
5. 접근성 우선 설계: 청각장애인을 주 사용자로 전제했다.


II 작품 제작

1. 작품 설계

본 작품 SoundShape는 음성의 운율과 인공지능을 이용해 화자의 감정을 추출하고, 이를 시각 언어로 번역해 영상 위에 자막과 함께 보여 주는 시스템이다. 설계의 목표는 크게 네 가지다. 첫째, 음성 입력에서 시각 출력까지 한 줄로 이어지는 실제 작동하는 end-to-end 시스템을 만든다. 둘째, "왜 분노가 빨강인가"라는 물음에 답할 수 있도록 모든 시각 규칙을 연구에 근거하게 한다. 셋째, 처음 본 사람도 직관적으로 이해할 수 있는 시각화를 목표로 한다. 넷째, 주 사용 언어인 한국어를 지원한다.

2. 작동 원리

SoundShape는 음성을 다음 단계로 처리한다.



[1] 전체 처리 파이프라인 참조.

음성 정규화: FFmpeg를 사용해 입력 음성 및 영상을 16 kHz 단일 채널 WAV로 변환한다. 이는 이후 모든 분석 모델이 요구하는 표준 형식이다.


자막 생성: OpenAI Whisper(faster-whisper, large-v3-turbo)로 발화를 글자와 단어 단위 타임스탬프로 변환한다. 침묵 구간을 기준으로 음성을 나누어, 발화 단위로 처리한다.

운율 추출: 각 발화 구간에서 Parselmouth(PRAAT)로 음높이(F0), 세기, 지터, 시머, 발화 속도 등 15종의 운율 특징을 추출한다. 이는 사람이 해석할 수 있는 명시적 단서다.

감정 분류: wav2vec2 기반 두 모델을 사용한다. 범주형(분노/기쁨/중립/슬픔)과 차원형(정서가, 각성, 우월성의 연속값)이다.

감정 결정(보정/하이브리드): 차원형 모델의 계통적 편향을 데이터 기반으로 보정하고, 범주형과 차원형을 결합한 하이브리드로 최종 감정을 정한다(범주형이 약한 부분을 차원형이 보완). 한국어는 텍스트 감성으로 정서가를 보조하되, 말투가 분명히 부정적이면 무시해 비꼴을 보존한다. 모델의 확신이 낮으면 시각을 중립화한다.

운율 변조: 측정된 지터 (Jitter) 및 시머 (Shimmer) 는 시각의 떨림 진폭을, 강도는 크기를, 발화 속도는 움직임 속도를 직접 조절한다. 따라서 같은 감정으로 분류된 두 음성도 더 떨리거나 크면 다르게 보인다.



[2] 감정→시각 매핑


시각 매핑: 감정을 도형, 색, 크기, 움직임으로 번역한다. 규칙은 연구에 근거하며, 하나의 설정에 정의되어 백엔드와 프론트엔드가 동일하게 읽는다.

시각화 출력: WebGL 셰이더로 감정 에너지 필드를 영상 위에 오버레이하고 자막과 동기화한다. 첫 구간을 짧게 처리해 약 6초 만에 재생을 시작하고, 이후를 재생보다 앞서 처리해 재생 중 지연을 0으로 만든다.

감정→시각 매핑의 근거

채널	규칙	근거
도형	각진 모양은 위협감을, 둥근 모양은 안정감을 표현한다.	Aronoff(1992); Bar & Neta(2006)
색(색상)	빨강, 파랑, 노랑, 회색은 범문화적으로 각각 분노, 슬픔, 행복, 중립감을 나타낸다.	Hupka(1997)
색(채도/명도)	채도는 각성에, 명도는 정서가에 비례한다.	Valdez & Mehrabian(1994)
크기	크기 또한 각성에 비례하여 커진다.	Russell(1980); Ohala(1994)
움직임	빠르고 거친 움직임은 분노나 고각성을 표현한다.	Pollick(2001); Banse & Scherer(1996)

3. 시스템 구성







[3] SoundShape 시스템 구성

SoundShape는 클라이언트-서버 구조다. 사용자는 웹 애플리케이션(파일 업로드/유튜브 링크)이나 크롬 확장 프로그램(유튜브상 실시간 오버레이)으로 접근하며, 무거운 분석은 백엔드 서버(FastAPI)가 담당한다. 매핑 규칙을 단일 설정으로 외부화하여, 백엔드(Python)와 프론트엔드(TypeScript)가 동일한 규칙을 읽고 출력의 바이트 단위가 같음을 자동 검증한다.

4. 작품 제작

제작 항목	내용	결과 이미지
백엔드 파이프라인	FFmpeg/Whisper/PRAAT/wav2vec2를 연결해, 발화 구간마다 자막, 운율, 감정을 추출하고 JSON 타임라인으로 만든다.	<pre> motion: { "citation": "Movement kinematics carry emotion: fast/jerky motion reads as anger/high-arousal, slow/smooth as sadness/low-arousal." "rules": [{ "when": { "arousal_lt": 0.4, "valence_lt": 0.0 }, "motion": { "type": "shake", "amplitude": 0.7, "speed": 0.9 }, "why": "High arousal + negative valence (anger-like) → sharp, jittery agitation." }, { "when": { "category": "fear" }, "motion": { "type": "tremor", "amplitude": 0.5, "speed": 1.0 }, "why": "Fear → fast, fine trembling." }, { "when": { "arousal_gt": 0.4 }, "motion": { "type": "pulse", "amplitude": 0.55, "speed": 0.7 }, "why": "High arousal + non-negative valence (joy/surprise) → energetic pulsing." }, { "when": { "category": "sadness", "arousal_lt": -0.2, "valence_lt": 0.0 }, "motion": { "type": "slow-drift", "amplitude": 0.25, "speed": 0.25 }, "why": "Calm sadness → slow horizontal drifting, like a sigh." }, { "when": { "category": "resignation" }, "motion": { "type": "sink", "amplitude": 0.4, "speed": 0.25 }, "why": "Resignation → slow downward sink, an exhale." }, { "when": { "category": "sincerity" }, "motion": { "type": "pulse", "amplitude": 0.22, "speed": 0.4 }, "why": "Warm sincerity → soft, gentle pulse." }], "default": { "type": "still", "amplitude": 0.0, "speed": 0.0 } } </pre>

감정 매핑 엔진	설정(config) 기반으로 감정을 시각으로 번역한다. 운율 변조 및 불확실성 중립화를 포함하며, Python/TS의 동일성을 검증한다.	 SoundShape - 감정별 시각화 감정별 시각화: 6가지 감정(Anger, Fear, Joy, Sadness, Surprise, Neutral)에 대한 시각적 표현. 각 감정은 특정 색상과 형태로 시각화되어 있으며, 각각의 시각화에는 'Emotion', 'Color', 'Shape' 정보가 표시되어 있다.
시각화 (WebGL)	프랙탈 노이즈로 부드러운 에너지 필드를 만들고 감정별 실루엣 안에 담는다.	 감정별 에너지 필드 시각화: 프랙탈 노이즈를 사용하여 부드러운 에너지 필드를 생성하고, 감정별 실루엣 안에 담는 시각화.
웹 애플리케이션	파일 및 유튜브 입력, 자막/시각화 토글, 감정 타임라인, 실시간 스트리밍 재생.	 SoundShape 웹 인터페이스: 사용자 인터페이스를 보여줌. "Drop an audio or video file here, or click to pick" 메시지와 업로드 아이콘이 표시되어 있다.
크롬 확장 프로그램	실제 유튜브 영상 위에 감정 필드를 실시간 오버레이. 유튜브 SPA 영상 전환(추천 클릭·자동재생·뒤로가기)을 이벤트와 videoId 감시로 감지해, 이전 분석을 정리(스트림 취소·오버레이 제거)하고 새 영상을 자동 재분석한다.	 유튜브 영상에 감정 필드 오버레이: 유튜브 영상 위에 감정 필드를 실시간 오버레이하는 시각화. 영상 하단에는 "I'm trying to make small talk."라는 자막이 표시되어 있다.

정확도 개선	차원형 보정 + 하이브리드 + 학습형 분류기로 감정 인식 정확도를 높였다 (영어 55→79.8%, 한국어 17.5→49.6%).	
자동화 테스트	핵심 로직과 실패 케이스를 검증하는 23개 자동화 테스트(pytest 활용).	<pre>{ "metadata": { "duration": 1.86, "sample_rate": 16000, "language": "en" }, "segments": [{ "t": 0.0, "duration": 1.7, "text": "I'm fine, really, I'm fine.", "words": [{ "word": "I'm", "start": 0.0, "end": 0.16, "probability": 0.98 }, ...], "prosody": { "f0_mean": 263.98, "jitter_local": 0.0124, "shimmer_local": 0.0533, "hnr_mean": 17.96, "speech_rate_approx": 80.0, ... }, "emotion": { "category": "joy", "valence": 1.0, "arousal": 0.52, "dominance": 0.42 }, "visual": { "shape": "expanding_burst", "color": { "h": 50, "s": 75.5, "l": 62 }, "size": 0.81, "motion": { "type": "pulse", "amplitude": 0.63, "speed": 0.87 } } }] }</pre>

III 작품 테스트

이 시스템은 음성에서 감정을 추출해 시각으로 번역한다는 점에서 기존 자막과 근본적으로 다르다. 따라서 "안정적으로 작동하는가 → 감정을 정확히 읽는가 → 실제로 사용자에게 도움이 되는가"를 단계적으로 검증해야 한다. 그중 가장 중요한 세 가지를 테스트한다.

- 시스템 안정성(자동화 테스트)
- 감정 인식 정확도
- 자막 + SoundShape의 감정 이해 향상 효과(사용자 실험)

따라서 위 세 가지를 각각 테스트하여 시스템의 안정성, 정확도, 실효성을 평가하고 개선점을 찾는다.

A. 시스템 안정성 테스트

1. 테스트 목적: 시스템 안정성

실제 발표 시연이나 사용 중에는 무음 구간, 손상된 파일, 잘못된 입력 등 예기치 못한 상황이 발생한다. 이때 시스템이 멈추거나 오작동하면 신뢰성을 잃는다. 따라서 핵심 로직(감정→시각 매핑 등)이 의도대로 동작하는지, 그리고 비정상 입력에도 충돌 없이 처리되는지를 자동으로 검증한다.

2. 테스트 방법: 시스템 안정성

2.1 사용 도구

도구	도구의 활용법
pytest (Python)	명령어 한 줄로 23개 자동화 테스트를 일괄 실행한다.

맥북 에어	백엔드 소스 코드와 테스트를 실행하는 개발 환경이다.
합성 입력 데이터	코드로 무음 음성과 손상된(음성이 아닌) 파일을 생성해 실패 상황을 인위적으로 만든다.

2.2 단계별 테스트 방법

1. 매핑 정확성/감정/운율 로직/실패 케이스의 세 종류로 총 23개의 테스트를 작성한다.
2. 코드로 무음 파일/손상 파일/잘못된 시간 구간을 생성한다.
3. 터미널에서 pytest를 실행한다.
4. 각 테스트의 통과 여부와, 비정상 입력에서 프로그램이 멈추지 않는지(충돌 여부)를 확인한다.
5. 백엔드(Python)와 프론트엔드(TypeScript)의 매핑 결과가 동일한지 별도로 대조한다.

3. 예상 결과: 시스템 안정성

핵심 로직은 모두 정상 동작하여 테스트가 전부 통과하고, 무음/손상/경계 입력에도 시스템이 멈추지 않고 안전하게 처리할 것이다.

4. 실제 결과: 시스템 안정성

테스트 분류	개수	통과	비고
매핑 정확성(연구 규칙 Python/TS 동일성)	7	7	분노=빨강/각진/떨림 등 규칙 일치
감정 및 운율 로직(보정, 하이브리드, 운율 변조)	6	6	-
음성 분할(침묵 기준 체크)	3	3	-
데이터 파싱(라벨 해석)	3	3	-
오디오 입출력 및 실패 케이스	4	4	무음/손상 파일/잘못된 구간 무충돌
합계	23	23	약 8초, 충돌 0건

5. 결과 분석: 시스템 안정성

예상대로 23개 전부 통과했고, 무음, 손상, 경계 입력 모두 충돌 없이 처리되었다. 특히 실패 케이스의 무충단을 확인하여 시연 중 돌발 입력에도 안전함을 입증했고, 백엔드와 프론트엔드 매핑이 동일함을 검증하여 두 실행 환경의 일관성을 확보했다. 즉, 시스템의 소프트웨어 품질과 견고성이 확인되었다.

B. 감정 인식 정확도 테스트

1. 테스트 목적: 감정 인식 정확도

"음성의 감정을 시각화한다"는 본 작품의 주장이 성립하려면, 그 전제인 감정 인식이 실제로 정확해야 한다. 따라서 주 사용 언어인 한국어와 비교 기준인 영어 두 언어에서 감정 인식 정확도를 객관적 데이터로 측정한다.

2. 테스트 방법: 감정 인식 정확도

2.1 사용 도구

도구	도구의 활용법
RAVDESS (영어)	배우가 8가지 감정을 연기한 음성으로, 정답 라벨이 있어 정확도 측정에 사용한다.
AIHub 「감정 분류를 위한 대화 음성」 (한국어)	자연스러운 대화 음성을 평가자 5인의 다수결로 7가지 감정으로 라벨링한 데이터다.
Parselmouth(PRAAT)	음높이, 세기, 지터, 시머 등 운율 특징을 추출한다.
wav2vec2	음성에서 감정 임베딩을 추출한다(한국어는 한국어 특화 XLSR-korean).
scikit-learn	분류기 학습, 교차검증, 정확도/혼동행렬 계산에 사용한다.

2.2 단계별 테스트 방법

1. 두 데이터셋을 준비한다(한국어는 평가자 5인 다수결로 최종 감정 라벨을 정한다).
2. 제로샷: 배포된 시스템(영어로 학습된 기성 모델)을 그대로 적용해 각 음성의 감정을 예측하고 정답과 비교한다.
3. 학습형: 각 음성에서 wav2vec2 임베딩과 PRAAT 운율 특징을 추출해 하나의 특징으로 결합한다.
4. 결합한 특징으로 분류기(SVM)를 학습하고, 처음 듣는 목소리로 평가하기 위해 영어는 화자 독립 교차 검증, 한국어는 층화 교차 검증으로 측정한다.
5. 정확도, F1, 혼동행렬, 그리고 운율-정답 상관(각성/정서가)을 계산한다. 또한 각 구성요소의 기여를 분리하기 위해, 동일 데이터·동일 fold·동일 seed에서 특징 구성만 바꾼 네 조건 (운율만/임베딩만/결합/결합+텍스트 보정)의 ablation을 수행한다. 또한 같은 프로토콜로 한국어 특화·다국어 임베딩과의 교체 비교를 수행한다.

3. 예상 결과: 감정 인식 정확도

기성 모델은 언어 및 도메인 차이로 완벽하지 않을 것이며, 운율은 각성(흥분도) 측에 강할 것이다. 한국어가 영어보다 낮고, 학습형이 제로샷보다 높을 것이다.

4. 실제 결과: 감정 인식 정확도

언어 / 데이터	제로샷(기성 모델)	학습형 분류기
영어 (RAVDESS, 연기 음성)	55.0 % (4분류)	79.8 % (4분류, 화자독립) / 74.2 % (8분류)
한국어 (AIHub, 자연 대화)	17.5 % (7분류, 우연=14.3 %)	49.6 % (7분류)

영어 운율-정답 상관: 각성 $r = 0.73$ (강함), 정서가 $r = 0.42$ (약함)

학습은 두 언어 모두 큰 폭으로 향상(영어 +25점, 한국어 +32점)

가장 잘 맞춘 감정: 영어=분노(F1 0.87), 한국어=공포(F1 0.65). 모두 고각성 감정이다.

조건	정확도	macro-F1	비고
A. 운율만	21.8%	0.211	PRAAT 14특징
B. 임베딩만	48.5%	0.484	XLSR-korean 1024차원
C. 결합 (최종 시스템)	49.6%	0.496	최종 시스템 구성

임베딩	특성	정확도	macro-F1
wav2vec2	영어 감정 특화	43.6%	0.436
XLS-R-300M	다국어 사전학습(무튜닝)	30.7%	0.307
XLSR-korean	한국어 특화	49.6%	0.496
HuBERT-korean	한국어 감정 특화	49.7%	0.496

채택한 XLSR-korean의 개선(43.6%→49.6%)은 McNemar 정확검정 $p < 0.001$ 로 통계적으로 유의하다.

한국어 튜닝 모델 두 종이 같은 수치로 수렴하고 무튜닝 다국어 모델은 오히려 하락하여, 개선의 요인은 언어 매칭임을 보여준다.

난이도(우연/상한) 보정 비교

	정확도	분류수	우연	우연 대비	인간 상한 대비
한국어 학습형	49.6%	7	14.3%	3.47x	96.3%
영어 학습형	79.8%	4	25%	3.19x	--
청인 (연기/5분류) [3]	66%	5	20%	3.30x	--

5. 결과 분석: 감정 인식 정확도

한국어 49.6 %는 절대값만 보면 낮아 보이지만, 과제의 난이도와 정답의 한계를 고려하면 사람에 근접한 수치다. 네 가지 근거로 이를 뒷받침한다.

1. 정답 자체에 상한이 있다. 한국어 데이터의 5인 평가자는 Fleiss $\kappa = 0.344$ ("보통") 수준으로만 일치했고, 만장일치는 17.4 %에 불과하며 4편 중 1편(25.8 %)은 다수표가 2표뿐이었다. 즉 자연발화의 7가지 감정은 사람조차 하나로 합의하지 못하는 본질적으로 모호한 과제다. 이때 한 평가자가 다수결을 맞히는 정확도는 51.5 %였다. 본 모델의 49.6 %는 이 인간 상한의 약 96 %에 도달한 값이다.
2. 난이도(우연)를 보정하면 영어 및 사람과 같은 수준이다. 7분류는 4/5분류보다 본질적으로 어렵다. 우연 대비로 환산하면 한국어 3.47배, 영어 3.19배, 연기 음성에 대한 청인 3.30배(66 %, 5분류) [3]로 모두 같은 구간에 있다. 즉, 한국어 모델은 더 어려운 문제를 같은 효율로 풀고 있다.
3. 낮은 제로샷은 오히려 우리 기여의 크기를 보여 준다. 한국어 제로샷 17.5 %는 우연(14.3 %)과 사실상 동일하다. 영어로 학습된 기성 모델이 한국어 자연발화에 무력하다는 점을 추정이 아닌 숫자로 직접 입증했다. 우리 방식은 여기에 +32.1점(상대 +183 %)을 더했고, 영어에서도 +25점(55→79.8 %)으로 언어에 종속되지 않는 일반화를 보였다.
4. 제품이 의존하는 축(각성)은 한국어에서도 신뢰할 수 있다. 시각의 핵심 채널(크기, 채도, 움직임)은 각성에 기반하는데, 각성은 음향만으로 잘 잡힌다(영어 $r = 0.73$). 실제로 가장 잘 맞춘 감정도 한국어=공포 및 영어=분노로 모두 고각성이었다. 반면 음향만으로 어려운 것은 정서가(영어 $r = 0.42$)로, 이는 음성 감정 인식 분야 전반의 '정서가 문제'이며 우리가 텍스트 보정을 도입한 이유다. 따라서 7분류 라벨의 정확도가 완벽하지 않아도, 사용자가 보는 시각 정보(각성 기반)는 한국어에서도 유지된다.
5. 나아가 ablation으로 각 구성요소의 역할을 분리해 확인했다. 분류 정확도는 임베딩이 주도하며(단독 48.5%), 운율 특징의 분류 기여는 +1.1%p로 작았다. 이는 설계와 일치한다: 운율 특징의 주 역할은 분류가 아니라 시각 변조(측정된 지터·시머·발화 속도가 떨림·크기·움직임 속도를 직접 구동)와 "왜 이렇게 보이는가"에 답하는 해석가능성이다. 텍스트 감성 보정은 예측 66건을 바꿨으나 29건을 개선하고 37건을 악화시켜 순 기여는 -0.5%p였고, 이 차이는 우연 범위다(이항검정 $p = 0.39$). 즉 텍스트 보정은 전체 정확도를 높이는 장치가 아니며, 설계 목적대로 음향 신호가 불확실한 구간에서 정서를 보조하고 확신 있는 어조(비꼼)를 보존하는 tie-breaker다. 그 실효는 사용자 실험의 비꼼·억눌린 감정 클립(0%→67%)에서 확인된다.

C. 감정 이해 향상 효과 테스트 (사용자 실험)

1. 테스트 목적: 감정 이해 향상 효과

본 작품의 존재 이유는 "청각장애인이 감정을 더 잘 이해하게 한다"이다. 따라서 소리를 끈 상태(청각장애 상황 모사)에서 자막만 볼 때와 자막+SoundShape를 볼 때의 감정 인식 정확도를 직접 비교하여, 작품이 실제로 효과가 있는지 검증한다.

2. 테스트 방법: 감정 이해 향상 효과

2.1 사용 도구

도구	도구의 활용법
SoundShape 웹앱	SoundShape ON/OFF 및 자막 ON/OFF 토글로 두 조건을 같은 화면에서

	전환한다.
감정 클립 8개	정답 감정이 정해진 짧은 영상. 일부는 비꼼 및 억눌린 감정(말과 뜻이 다른 경우)을 포함한다.
참가자 6인	소리를 끄고 시청하는 정상 청각자에게는 청각장애 상황의 인정된 대체 실험 방식이다.
분석 스크립트(Python)	응답을 정답과 비교해 조건별 정확도와 대응표본 t검정을 자동 계산한다.

2.2 단계별 테스트 방법

1. 8개 클립과 각 클립의 정답 감정(answer key)을 준비한다.
2. 참가자마다 클립-조건 배정을 form으로 교차 균형해, 같은 클립이 두 조건에 고르게 배정되도록 한다(클립 난이도 편향 제거).
3. 소리를 끈 상태로, 각 클립을 조건 A(자막만) 또는 B(자막+SoundShape)로 한 번씩 보여 준다.
4. 각 클립 직후 감정 6지선다(기쁨/슬픔/분노/공포/놀람/중립)와 확신도(1~5)를 응답받아 기록한다.
5. 분석 스크립트로 조건별 정확도를 집계하고, 대응표본 t검정으로 유의성을 검증한다.

3. 예상 결과: 감정 이해 향상 효과

자막+SoundShape(B)가 자막만(A)보다 감정 정확도가 높을 것이며, 특히 비꼼 및 억눌린 감정에서 차이가 클 것이다.

4. 실제 결과: 감정 이해 향상 효과

조건	감정 인식 정확도
A. 자막만	27 %
B. 자막 + SoundShape	73 %

향상폭	+46 %p
대응표본 t검정	$p = 0.016 \rightarrow$ 통계적으로 유의 ($p < 0.05$)
비꼼 및 억눌린 감정 클립	0% $\rightarrow$ 67 %
평균 확신도	3.3 $\rightarrow$ 3.5

5. 결과 분석: 감정 이해 향상 효과

예상대로 자막+SoundShape가 우세했으며, 그 효과 크기가 매우 컸다(+46 %p). 특히 비꼼 및 억눌린 감정에서 0 % $\rightarrow$ 67 %의 향상은, 자막만으로는 아무도 비꼼을 읽지 못했지만 SoundShape를 더하자 다수가 정확히 읽었음을 뜻한다. 이는 "말투가 글자를 이긴다"는 본 작품의 핵심 가설을 직접 입증하며, 결과가 통계적으로

유의($p=0.016$)하여 우연이 아님을 보였다. 다만 표본이 6인으로 적고, 정상 청각자의 무음 실험이며, 같은 클립을 두 조건에서 본 설계라는 한계가 있다. 이는 추후 청각장애인 당사자 및 대규모 표본으로 보완할 부분이다.

IV 해석 & 결론

1. 결론

테스트 결과에 따라 최종 작품 SoundShape의 실현 가능성이 증명되었다. 먼저 시스템의 안정성을 검증한 결과, 핵심 로직과 실패 케이스를 검증하는 23개의 자동화 테스트가 전부 통과했으며, 무음, 손상, 경계 입력에서도 프로그램이 멈추지 않고 충돌 0건으로 안전하게 처리되었다. 또한 백엔드(Python)와 프론트엔드(JavaScript)의 매핑 결과가 바이트 단위로 동일함을 확인하여 두 실행 환경의 일관성을 확보했다. 따라서 시스템이 시연 및 실사용 환경에서 신뢰할 수 있는 소프트웨어 품질과 견고성을 갖췄음을 입증했다. 그 다음으로 감정 인식 정확도를 측정한 결과, 학습형 분류기를 통해 영어는 55%에서 79.8%로, 한국어는 17.5%에서 49.6%로 향상되었다. 한국어 49.6%는 절대 수치만 보면 낮아 보이나, 같은 데이터를 라벨링한 평가자 5인조차 Fleiss κ 0.344의 '보통' 수준으로만 일치하고 한 평가자가 다수결을 맞히는 인간 상한이 51.5%라는 점을 고려하면, 이는 인간 상한의 약 96%에 도달한 값이다. 즉, 모델의 한계라기보다 정답 자체가 본질적으로 모호한 과제임을 의미한다. 또한 우연 대비로 환산하면 한국어 3.47배, 영어 3.19배, 청인 3.30배로 모두 같은 구간에 있어, 한국어 모델이 더 어려운 7분류 문제를 같은 효율로 풀고 있음을 보여 준다. 특히 시각화의 핵심 채널인 크기, 채도, 움직임에 의존하는 각성은 음향만으로 신뢰성 있게 측정되므로(영어 $r=0.73$), 한국어에서도 사용자가 보는 감정 정보는 유지된다. 마지막으로 작품의 실효성을 사용자 실험으로 검증한 결과, 소리를 끈 상태에서 자막만 본 경우 감정 인식 정확도는 27%에 그쳤으나 자막과 SoundShape를 함께 본 경우 73%로 46%p 상승했으며, 그 차이는 대응표본 t검정 결과 $p=0.016$ 으로 통계적으로 유의했다. 특히 말과 뜻이 반대인 비꼼 및 억눌린 감정 클립에서는 0%에서 67%로 향상되어, 자막만으로는 아무도 읽지 못한 반어를 다수가 정확히 읽어 냈다. 나아가 이 73%는 청인이 목소리를 직접 듣고 감정을 인식하는 수준인 약 66%에 근접하는 값으로, SoundShape가 소리를 듣지 못하는 시청자를 청인이 귀로 감정을 읽는 수준 가까이 되돌림을 뜻한다. 따라서 위 테스트들은 최종 작품 SoundShape의 모든 기능이 요구하는 주 역할을 수행할 수 있음을 입증했으며, 안정성, 정확도, 실효성이 모두 양호하게 증명되어 실현 가능성을 분명하게 보여 주었다. 이로써 SoundShape는 대사만 전달하던 기존 자막을 감정까지 전달하는 형태로 확장했다. 나아가 청각장애인을 비롯해 자폐 스펙트럼 당사자 등 감정 정보에서 소외되던 정보 약자의 이해를 돕는 역할도 함께 수행한다. 마지막으로, 더 나아가 미디어 접근성 기술의 발전 및 연구 가능성을 제시한다. 모든 매핑 규칙이 단일 설정으로 외부화되어 새로운 언어 및 도메인으로 확장할 수 있으므로, 미디어 접근권을 넓히는 보조 기술로서 사회에 기여할 수 있다. 따라서 이 시스템은 청각장애인의 문화적 접근권을 확대하고 정보 약자의 미디어 이해를 원활하게 하는 데에 도움을 준다.

2. 추후 개선사항

SoundShape의 실현 가능성이 증명되었지만 여전히 잠재적 한계와 개선 여지가 존재한다. 먼저 한국어 감정 인식 정확도가 개선되어야 한다. 현재 한국어 평가는 화자 식별 정보가 없어 층화 교차검증에 머물렀으므로, 향후 화자독립 검증이 가능한 데이터로 일반화 성능을 재확인하고 더 큰 학습 데이터를 적용해 정확도를 더 끌어올릴 수 있다(한국어 전용 음성 표현 XLSR-korean의 적용은 완료: 43.6→49.6%). 또한 음향만으로는 각성은 잘 측정되나 정서가(긍/부정)가 약하다는 한계가 있는데(영어 $r=0.42$), 이는 음성 감정 인식 분야 전반의 공통 문제로 표정, 문맥, 텍스트를 함께 활용하는 멀티모달 방식을 통해 보완할 수 있다. 다음으로 사용자 실험이 확대되어야 한다. 현재 결과는 통계적으로 유의하나 참가자가 6인이며, 정상 청각자가 소리를

끄고 시청한 모사 실험이고, 같은 클립을 두 조건에서 본 설계라는 한계가 있다. 따라서 청각장애인 당사자를 대상으로 대규모 피험자 간(between-subjects) 설계와 실제 시청 환경에서 효과를 재검증해야 한다. 또한 색에 의존하는 시각 채널을 보완하기 위해 색각이상 사용자를 위한 형태 및 패턴 대비를 강화하고, 자막 위치, 크기, 시각 강도의 사용자 맞춤 옵션과 시각 언어 학습을 돕는 범례, 온보딩, 모바일 지원을 추가할 수 있으며, 모양과 감정의 대응이 얼마나 직관적인지는 별도의 사용자 연구로 검증할 수 있다. 마지막으로 크롬 웹스토어 정식 출시를 목표로 유튜브 외 다양한 영상 플랫폼으로 적용 범위를 넓히고, 개인정보 보호를 위한 온디바이스(local) 처리 옵션을 마련할 수 있다. 이와 같은 추후 개선 사항을 고려해 SoundShape를 발전시킨다면 보다 정확하고 효율적으로 기능할 수 있을 것이다.

[출처]

- [1] Mehrabian, A., & Wiener, M. (1967). Decoding of inconsistent communications. *Journal of Personality and Social Psychology*, 6(1), 109–114.
- [2] Mehrabian, A., & Ferris, S. R. (1967). Inference of attitudes from nonverbal communication in two channels. *Journal of Consulting Psychology*, 31(3), 248–252.
- [3] Banse, R., & Scherer, K. R. (1996). Acoustic profiles in vocal emotion expression. *Journal of Personality and Social Psychology*, 70(3), 614–636.
- [4] Juslin, P. N., & Laukka, P. (2003). Communication of emotions in vocal expression and music performance: Different channels, same code? *Psychological Bulletin*, 129(5), 770–814.
- [5] World Health Organization. (2021). *World Report on Hearing*.
- [6] 보건복지부 (2025. 4. 17. 보도자료), 「2024년 등록장애인 현황」
- [7] Rashid, R., Vy, Q., Hunt, R., & Fels, D. I. (2008). Dancing with Words: Using Animated Text for Captioning. *International Journal of Human–Computer Interaction*, 24(5), 505–519.
- [8] Cheang, H. S., & Pell, M. D. (2008). The sound of sarcasm. *Speech Communication*, 50(5), 366–381.
- [9] Russell, J. A. (1980). A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6), 1161–1178.
- [10] Grosbras, M.-H., Ross, P. D., & Belin, P. (2018). Categorical emotion recognition from voice improves during childhood and adolescence. *Scientific Reports*, 8, 14791.
- [11] Zhang, M., Xu, S., Chen, Y., Lin, Y., Ding, H., & Zhang, Y. (2022). Recognition of affective prosody in autism spectrum conditions: A systematic review and meta-analysis. *Autism*, 26(4), 798–813.
- [12] Dawel, A., O’Kearney, R., McKone, E., & Palermo, R. (2012). Not just fear and sadness: Meta-analytic evidence of pervasive emotion recognition deficits for facial and vocal expressions in psychopathy. *Neuroscience & Biobehavioral Reviews*, 36(10), 2288–2304.
- [13] Aronoff, J., Woike, B. A., & Hyman, L. M. (1992). Which are the stimuli in facial displays of anger and happiness? Configurational bases of emotion recognition. *Journal of Personality and Social Psychology*, 62(6), 1050–1066.
- [14] Bar, M., & Neta, M. (2006). Humans prefer curved visual objects. *Psychological Science*, 17(8), 645–648.
- [15] Hupka, R. B., Zaleski, Z., Otto, J., Reidl, L., & Tarabrina, N. V. (1997). The colors of anger, envy, fear, and jealousy: A cross-cultural study. *Journal of Cross-Cultural Psychology*, 28(2), 156–171.
- [16] Valdez, P., & Mehrabian, A. (1994). Effects of color on emotions. *Journal of Experimental Psychology: General*, 123(4), 394–409.
- [17] Ohala, J. J. (1994). The frequency code underlies the sound-symbolic use of voice pitch. In L. Hinton, J. Nichols, & J. J. Ohala (Eds.), *Sound symbolism* (pp. 325–347). Cambridge University Press.
- [18] Pollick, F. E., Paterson, H. M., Bruderlin, A., & Sanford, A. J. (2001). Perceiving affect from arm movement.

Cognition, 82(2), B51–B61.

[19] FCB Chicago, Academy of Motion Picture Arts and Sciences, & Chicago Hearing Society. (2025). Caption with Intention. 2025 Cannes Lions Titanium Lion.